

UNIVERSIDADE FEDERAL DO AMAZONAS
PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA
DOUTORADO EM INFORMÁTICA

**MODELAGEM DE FALHAS E ESTIMAÇÃO DA
VIDA
REMANESCENTE DE BATERIAS DE ÍONS DE
LÍTIO
UTILIZANDO A PLATAFORMA PyBaMM**

Pedro Victor dos Santos Oliveira

Manaus, AM

2026

Pedro Victor dos Santos Oliveira

MODELAGEM DE FALHAS E ESTIMAÇÃO DA VIDA REMANESCENTE DE BATERIAS DE ÍONS DE LÍTIO UTILIZANDO A PLATAFORMA PyBaMM

Tese apresentada ao Programa de Pós-Graduação em Informática da Universidade Federal do Amazonas como requisito parcial para a obtenção do título de Doutor em Informática, na área de concentração Inteligência Computacional.

Orientador: Prof. Dr. Orientador Sobrenome

Co-orientador: Prof. Dr. Co-orientador Sobrenome

Manaus, AM
2026

Oliveira, Pedro Victor dos Santos

Modelagem de Falhas e Estimação da Vida Remanescente de Baterias de Íons de Lítio Utilizando a Plataforma PyBaMM / Pedro Victor dos Santos Oliveira. – Manaus, 2026-

?? p. : il. (algumas color.) ; 30 cm.

Supervisor: Prof. Dr. Orientador Sobrenome

Tese (Doutorado) – Universidade Federal do Amazonas – UFAM

Programa de Pós-Graduação em Informática – PPGI

Doutorado em Informática, 2026.

1. Baterias de íons de lítio. 2. Modelagem eletroquímica. 3. Doyle-Fuller-Newman. 4. Diagnóstico de falhas. 5. Vida remanescente. 6. PyBaMM. I. Prof. Dr. Orientador Sobrenome. II. Universidade Federal do Amazonas. III. Programa de Pós-Graduação em Informática. IV. Título.

Pedro Victor dos Santos Oliveira

MODELAGEM DE FALHAS E ESTIMAÇÃO DA VIDA REMANESCENTE DE BATERIAS DE ÍONS DE LÍTIO UTILIZANDO A PLATAFORMA PyBaMM

Tese apresentada ao Programa de Pós-Graduação em Informática da Universidade Federal do Amazonas como requisito parcial para a obtenção do título de Doutor em Informática.

Aprovada em _____ de _____ de 2026.

BANCA EXAMINADORA

Prof. Dr. Orientador Sobrenome

Orientador

Universidade Federal do Amazonas

Prof. Dr. Membro II

Universidade Federal do Amazonas

Prof. Dr. Membro III

Universidade Estadual do Amazonas

Prof. Dr. Membro IV

Instituto Nacional de Pesquisas da
Amazônia – INPA

Prof. Dr. Membro V

Universidade de São Paulo

*À minha família, pelo apoio incondicional
em cada etapa desta jornada.
À memória de todos que dedicaram sua vida
ao avanço da ciência e da tecnologia.*

Acknowledgements

À Universidade Federal do Amazonas (UFAM) e ao Programa de Pós-Graduação em Informática (PPGI) pela estrutura e apoio institucional imprescindíveis para a realização desta pesquisa.

Ao meu orientador, pela paciência, rigor científico e ensinamentos que moldaram minha formação como pesquisador.

À Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) e ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) pelo apoio financeiro por meio de bolsa de doutorado.

À comunidade de desenvolvimento do PyBaMM (*Python Battery Mathematical Modelling*), em especial à equipe *pybamm-team* da Universidade de Oxford, pela disponibilização de uma plataforma de simulação eletroquímica de excelência e acesso aberto.

Aos colegas do laboratório, pelas discussões técnicas, revisões e pelo companheirismo durante os longos períodos de pesquisa.

À minha família, pelo suporte emocional e pela compreensão durante os momentos de dedicação exclusiva ao trabalho acadêmico.

*“A battery is a thermodynamic machine.
Understanding its failure is understanding life itself.”*
– **John Newman**

Abstract

O crescimento acelerado da eletroabilidade e dos sistemas de armazenamento de energia renovável tornou as baterias de íons de lítio (BIL) componentes críticos em aplicações que vão desde veículos elétricos a redes de energia inteligentes. A detecção precoce de falhas e a estimativa precisa da vida remanescente útil (*Remaining Useful Life* – RUL) dessas baterias são fundamentais para garantir segurança operacional, reduzir custos de manutenção e maximizar o aproveitamento energético. Esta tese apresenta um ambiente computacional abrangente para modelagem eletroquímica de falhas e estimativa de RUL em BIL, desenvolvido sobre a plataforma *Python Battery Mathematical Modelling* (PyBaMM). Adota-se o modelo de Doyle-Fuller-Newman (DFN) como base física, parametrizado com os conjuntos Chen2020 e OKane2022, que capturam com fidelidade os fenômenos de transporte iônico, condutividade elétrica e degradação de eletrodos. O trabalho modela quatro classes de mecanismos de degradação acoplados: crescimento da camada de interface eletroquímica sólida (SEI), deposição de lítio metálico (*lithium plating*), mecânica de partículas com expansão e fissuramento, e perda de material ativo por processos induzidos por tensão mecânica. Para diagnóstico de falhas, propõe-se um modelo sistemático de injeção de falhas em sensores (corrente, tensão e temperatura) e atuadores (conectores de terminais e sistema de resfriamento), cobrindo os modos *bias*, *drift* e *stuck*. Os experimentos de simulação são executados com o solver IDAKLU sob protocolo CC-CV (*Constant Current* – *Constant Voltage*), com ciclos de formação, envelhecimento e verificação de desempenho. Os resultados demonstram que o framework desenvolvido reproduz com precisão a queda de capacidade e o aumento de resistência interna ao longo dos ciclos, além de permitir a identificação de assinaturas distintas para cada modo de falha. A plataforma constitui base metodológica para sistemas de gerenciamento de bateria (BMS) inteligentes e para futuros trabalhos de aprendizado de máquina aplicado ao prognóstico de baterias.

Palavras-chave: Baterias de íons de lítio. Modelo de Doyle-Fuller-Newman. PyBaMM. Diagnóstico de falhas. Vida remanescente útil. Degradação eletroquímica. Sensor de corrente. Sistema de resfriamento. Gerenciamento de bateria.

Abstract

The rapid growth of electromobility and renewable energy storage systems has made lithium-ion batteries (LIBs) critical components in applications ranging from electric vehicles to smart energy grids. Early fault detection and accurate estimation of the Remaining Useful Life (RUL) of these batteries are essential to ensure operational safety, reduce maintenance costs, and maximize energy utilization. This thesis presents a comprehensive computational environment for electrochemical fault modeling and RUL estimation in LIBs, developed on the Python Battery Mathematical Modelling (PyBaMM) platform. The Doyle-Fuller-Newman (DFN) model is adopted as the physical basis, parameterized with the Chen2020 and OKane2022 parameter sets, which faithfully capture ionic transport phenomena, electrical conductivity, and electrode degradation. The work models four classes of coupled degradation mechanisms: Solid Electrolyte Interphase (SEI) layer growth, lithium plating, particle mechanics with swelling and cracking, and loss of active material through stress-induced processes. For fault diagnosis, a systematic fault injection model is proposed for sensors (current, voltage, and temperature) and actuators (terminal connectors and cooling system), covering bias, drift, and stuck fault modes. Simulation experiments are executed with the IDAKLU solver under a CC-CV (Constant Current – Constant Voltage) protocol, including formation, aging, and performance verification cycles. Results demonstrate that the developed framework accurately reproduces capacity fade and internal resistance growth over cycles, while enabling the identification of distinct signatures for each fault mode. The platform constitutes a methodological foundation for intelligent Battery Management Systems (BMS) and future machine learning work applied to battery prognosis.

Keywords: Lithium-ion batteries. Doyle-Fuller-Newman model. PyBaMM. Fault diagnosis. Remaining Useful Life. Electrochemical degradation. Current sensor. Cooling system. Battery management.

List of Figures

Figure 1	– Hierarquia de modelos matemáticos para baterias de íons de lítio, classificados por fidelidade física e custo computacional.	32
Figure 2	– Arquitetura do framework de injeção de falhas. A simulação DFN gera sinais reais que são corrompidos pela função <code>falha_sensor()</code> antes de chegarem ao BMS.	40
Figure 3	– Curvas de descarga do modelo DFN-Chen2020 simuladas (linhas sólidas) comparadas com dados experimentais (marcadores) para diferentes taxas de C. Temperatura: 25 °C.	45
Figure 4	– Queda de capacidade normalizada ao longo de 10 ciclos de envelhecimento acelerado (1C). O ponto vermelho indica a capacidade medida no ciclo de verificação a C/10.	46
Figure 5	– Sinais de corrente original e com falhas injetadas (bias, drift e stuck) durante um ciclo de carga/descarga. As barras verticais indicam os instantes de transição de fase (descarga → repouso → carga).	47
Figure 6	– Sinais de tensão original e com falhas injetadas (bias, drift e stuck). A linha tracejada indica o limiar de sobretensão (4.2 V).	48
Figure 7	– Temperatura da célula (real e medida com falhas) durante ciclo de carga/descarga a 1C. A linha tracejada superior indica o limiar de proteção térmica ($T_{max} = 45\text{ °C}$).	49
Figure 8	– Temperatura da célula (eixo esquerdo, em °C) e tensão terminal (eixo direito, em V) para três cenários de transferência de calor: nominal ($h = 10$), insuficiente ($h = 2$) e excessivo ($h = 30$).	50
Figure 9	– Estequiometrias de lítio no ânodo (x) e cátodo (y) durante um ciclo CC-CV 4.2V. Os pontos de operação plena carga/descarga são indicados.	51

List of Tables

Table 1	– Principais dependências do ambiente de simulação.	37
Table 2	– Parâmetros dos cenários de falha no sistema de resfriamento.	42
Table 3	– Contribuição relativa dos mecanismos de degradação após 10 ciclos de envelhecimento a 1C.	46
Table 4	– Comparação das métricas de desempenho dos protocolos CC-CV avaliados.	50
Table 5	– Índices de sensibilidade de Morris (μ^*) para os parâmetros do modelo DFN-OKane2022 em relação à capacidade após 10 ciclos.	52

List of abbreviations and acronyms

ABNT	Associação Brasileira de Normas Técnicas
BIL	Baterias de Íons de Lítio
BMS	<i>Battery Management System</i> (Sistema de Gerenciamento de Bateria)
CC	Corrente Constante (<i>Constant Current</i>)
CC-CV	Corrente Constante – Tensão Constante (<i>Constant Current – Constant Voltage</i>)
CV	Tensão Constante (<i>Constant Voltage</i>)
DAE	Equações Diferenciais Algébricas (<i>Differential Algebraic Equations</i>)
DFN	Modelo de Doyle-Fuller-Newman
EDP	Equações Diferenciais Parciais
EDO	Equações Diferenciais Ordinárias
EIS	Espectroscopia de Impedância Eletroquímica
FDI	Detecção e Isolamento de Falhas (<i>Fault Detection and Isolation</i>)
IDAKLU	<i>Implicit DAE solver with KLU sparse linear solver</i>
Li	Lítio
LFP	Fosfato de Ferro Lítio (<i>Lithium Iron Phosphate</i>)
NMC	Óxido de Níquel Manganês Cobalto (<i>Nickel Manganese Cobalt Oxide</i>)
NCA	Óxido de Níquel Cobalto Alumínio (<i>Nickel Cobalt Aluminium Oxide</i>)
OCP	Potencial de Circuito Aberto (<i>Open Circuit Potential</i>)
PyBaMM	<i>Python Battery Mathematical Modelling</i>
RUL	Vida Remanescente Útil (<i>Remaining Useful Life</i>)
SEI	Interface Eletroquímica Sólida (<i>Solid Electrolyte Interphase</i>)
SOC	Estado de Carga (<i>State of Charge</i>)
SOH	Estado de Saúde (<i>State of Health</i>)

SPM Modelo de Partícula Única (*Single Particle Model*)

UFAM Universidade Federal do Amazonas

List of symbols

c_s	Concentração de lítio no eletrodo sólido [mol m^{-3}]
c_e	Concentração de lítio no eletrólito [mol m^{-3}]
D_s	Coefficiente de difusão de sólido [$\text{m}^2 \text{s}^{-1}$]
D_e	Coefficiente de difusão do eletrólito [$\text{m}^2 \text{s}^{-1}$]
η	Sobretensão de eletrodo [V]
ϕ_s	Potencial elétrico do sólido [V]
ϕ_e	Potencial elétrico do eletrólito [V]
j	Densidade de fluxo de lítio interfacial [$\text{mol m}^{-2} \text{s}^{-1}$]
j_0	Densidade de corrente de troca [A m^{-2}]
R_s	Raio da partícula de eletrodo [m]
σ_s	Condutividade elétrica do sólido [S m^{-1}]
κ	Condutividade iônica do eletrólito [S m^{-1}]
T	Temperatura [K]
F	Constante de Faraday [$96\,485 \text{ C mol}^{-1}$]
R	Constante universal dos gases [$8.314 \text{ J mol}^{-1} \text{ K}^{-1}$]
α	Coefficiente de transferência de carga [-]
δ_{SEI}	Espessura da camada SEI [m]
h	Coefficiente de transferência de calor [$\text{W m}^{-2} \text{ K}^{-1}$]
Q_{cap}	Capacidade nominal da célula [A h]

Contents

1	INTRODUÇÃO	27
1.1	Contextualização e Motivação	27
1.2	Objetivos	28
1.2.1	Objetivo Geral	28
1.2.2	Objetivos Específicos	28
1.3	Hipóteses de Pesquisa	28
1.4	Organização da Tese	29
2	REVISÃO BIBLIOGRÁFICA	31
2.1	Baterias de Íons de Lítio: Princípios e Eletroquímica	31
2.1.1	Arquitetura e Componentes	31
2.1.2	Reações Eletroquímicas	31
2.2	Modelos Matemáticos para Simulação de Baterias	31
2.2.1	Hierarquia de Modelos	31
2.2.2	O Modelo de Doyle-Fuller-Newman (DFN)	32
2.2.2.1	Transporte de lítio no eletrodo sólido	32
2.2.2.2	Transporte de lítio no eletrólito	33
2.2.2.3	Conservação de carga no sólido	33
2.2.2.4	Conservação de carga no eletrólito	33
2.2.2.5	Cinética de eletrodo – Equação de Butler-Volmer	33
2.2.3	Modelo Térmico	33
2.3	Mecanismos de Degradação em BIL	34
2.3.1	Crescimento da Camada SEI	34
2.3.2	Deposição de Lítio Metálico (<i>Lithium Plating</i>)	34
2.3.3	Mecânica de Partículas – Expansão e Fissuramento	34
2.3.4	Perda de Material Ativo (LAM)	35
2.4	Diagnóstico e Prognóstico em Sistemas de Bateria	35
2.4.1	Modelos de Falhas em Sensores	35
2.4.2	Estimação de Estado de Saúde (SOH) e Vida Remanescente (RUL)	35
2.5	A Plataforma PyBaMM	36
2.5.1	Arquitetura e Filosofia de Design	36
2.5.2	Conjunto de Parâmetros Chen2020	36
2.5.3	Conjunto de Parâmetros OKane2022	36
3	METODOLOGIA	37
3.1	Ambiente Computacional	37

3.2	Estrutura do Projeto	37
3.3	Configuração do Modelo DFN	38
3.3.1	Inicialização do Modelo	38
3.3.2	Configuração do Modelo de Degradação	38
3.4	Framework de Injeção de Falhas em Sensores	39
3.4.1	Arquitetura do Framework	39
3.4.2	Implementação do Modelo de Falha	40
3.4.3	Falhas Específicas por Sensor	41
3.4.3.1	Sensor de Corrente	41
3.4.3.2	Sensor de Tensão	41
3.4.3.3	Sensor de Temperatura	42
3.5	Modelagem de Falhas em Atuadores	42
3.5.1	Falha em Conectores de Terminais	42
3.5.2	Falha no Sistema de Resfriamento	42
3.6	Protocolos de Carregamento	43
4	RESULTADOS E DISCUSSÃO	45
4.1	Validação do Modelo DFN com Chen2020	45
4.2	Resultados das Simulações de Degradação	45
4.2.1	Evolução da Capacidade ao Longo dos Ciclos	45
4.2.2	Contribuição de Cada Mecanismo de Degradação	46
4.2.3	Perfis de Tensão e Corrente Durante Envelhecimento	46
4.3	Resultados das Simulações de Falhas em Sensores	47
4.3.1	Sensor de Corrente	47
4.3.2	Sensor de Tensão	48
4.3.3	Sensor de Temperatura	48
4.4	Resultados das Simulações de Falhas em Atuadores	49
4.4.1	Falhas em Conectores de Terminais	49
4.4.2	Falhas no Sistema de Resfriamento	49
4.5	Análise Comparativa dos Métodos de Carregamento	50
4.6	Análise do Estado de Saúde do Eletrodo (Electrode SOH)	51
4.7	Análise de Sensibilidade	51
5	CONCLUSÃO	53
5.1	Síntese das Contribuições	53
5.2	Validação das Hipóteses de Pesquisa	53
5.3	Limitações	54
5.4	Trabalhos Futuros	54
	BIBLIOGRAPHY	57

APPENDIX 59

	APPENDIX A – NOTEBOOKS DO PROJETO – SUMÁRIO DE	
	IMPLEMENTAÇÃO	61
A.1	Módulo: Exemplos (18 notebooks)	61
A.2	Módulo: Simulação de Falhas (9 notebooks)	61
	APPENDIX B – CONFIGURAÇÃO DO AMBIENTE DE DESEN-	
	VOLVIMENTO	63

1 INTRODUÇÃO

O século XXI é marcado por uma transição energética sem precedentes. A crescente demanda por descarbonização dos transportes e pela integração de fontes de energia renováveis intermitentes às redes elétricas impõe desafios tecnológicos complexos na área de armazenamento de energia. Neste cenário, as baterias de íons de lítio (BIL) emergem como a tecnologia de armazenamento eletroquímico dominante, em razão de sua elevada densidade de energia (150 W h kg^{-1} to 300 W h kg^{-1}), alta eficiência de carga e descarga, baixa taxa de autodescarga e ciclo de vida consideravelmente superior às tecnologias predecessoras [1].

O mercado global de baterias de íons de lítio ultrapassou \$100 bilhões de dólares em 2024, com projeções de crescimento para além de \$300 bilhões até 2030, impulsionado principalmente pela adoção massiva de veículos elétricos (EVs) e pelo desenvolvimento de sistemas de armazenamento de energia em escala de rede [2]. No contexto brasileiro, a UFAM e instituições parceiras têm liderado pesquisas aplicadas à Amazônia, onde soluções de armazenamento são fundamentais para o atendimento de comunidades isoladas não conectadas ao Sistema Interligado Nacional.

1.1 Contextualização e Motivação

Apesar de suas vantagens, as BIL estão sujeitas a mecanismos de degradação progressivos que reduzem gradualmente sua capacidade e eficiência ao longo do tempo. Falhas em sistemas de baterias podem ter consequências graves, que vão desde a perda de autonomia de veículos elétricos até incêndios por degradação térmica (*thermal runaway*). Incidentes com baterias em aviões Boeing 787 Dreamliner (2013), scooters elétricas e dispositivos móveis têm reforçado a necessidade crítica de sistemas de diagnóstico robustos [3].

O *Battery Management System* (BMS) é o componente eletrônico responsável por monitorar, controlar e proteger a bateria. Sua confiabilidade depende diretamente da integridade dos sensores de corrente, tensão e temperatura, bem como dos atuadores (relés, sistema de resfriamento). Falhas nesses componentes podem comprometer as estimativas de estado de carga (SOC) e estado de saúde (SOH), levando a decisões erradas de controle que aceleram a degradação ou geram condições de segurança [4].

A modelagem matemática de alta fidelidade, baseada em princípios eletroquímicos de primeiros princípios (*physics-based models*), surge como a abordagem mais promissora para a compreensão profunda dos mecanismos de falha e para o desenvolvimento de algoritmos de diagnóstico e prognóstico de RUL. O modelo de Doyle-Fuller-Newman (DFN) [5], desenvolvido na década de 1990, representa o padrão-ouro da modelagem eletroquímica de

BIL, capturando com fidelidade os fenômenos físico-químicos no interior das células.

1.2 Objetivos

1.2.1 Objetivo Geral

Desenvolver, implementar e validar um ambiente computacional abrangente para modelagem eletroquímica de falhas e estimação da vida remanescente de baterias de íons de lítio, utilizando a plataforma *Python Battery Mathematical Modelling* (PyBaMM) como base de simulação.

1.2.2 Objetivos Específicos

1. Implementar o modelo de Doyle-Fuller-Newman (DFN) com os conjuntos de parâmetros Chen2020 e OKane2022 no ambiente PyBaMM;
2. Modelar e simular quatro mecanismos acoplados de degradação eletroquímica: crescimento SEI, deposição de lítio metálico, mecânica de partículas e perda de material ativo;
3. Desenvolver um framework sistemático de injeção de falhas em sensores (corrente, tensão, temperatura) com os modos bias, drift e stuck;
4. Modelar falhas em atuadores, incluindo conectores de terminais e sistema de resfriamento, analisando o impacto térmico e elétrico nas curvas de descarga;
5. Analisar e comparar protocolos de carregamento CC-CV com diferentes tensões de corte e suas influências na degradação da célula;
6. Estabelecer bases metodológicas para integração de algoritmos de aprendizado de máquina para estimação de RUL.

1.3 Hipóteses de Pesquisa

- H1. A combinação do modelo DFN com os mecanismos de degradação acoplados do conjunto OKane2022 reproduz com precisão (erro $< 5\%$) as curvas de capacidade de células reais submetidas a envelhecimento acelerado;
- H2. O modelo de injeção de falhas proposto gera assinaturas eletroquímicas distintas e identificáveis por técnicas de processamento de sinal para cada modo de falha em sensores e atuadores;

- H3. A variação do coeficiente de transferência de calor (h) em $\pm 70\%$ do valor nominal causa desvios de temperatura superiores a 5°C que impactam significativamente a capacidade entregue da célula.

1.4 Organização da Tese

O restante deste documento está organizado da seguinte forma:

- **Capítulo 2:** apresenta a revisão bibliográfica sobre química de BIL, modelos matemáticos, mecanismos de degradação, técnicas de FDI e a plataforma PyBaMM;
- **Capítulo 3:** descreve a metodologia de implementação, incluindo o ambiente computacional, os modelos adotados, o protocolo de simulação e o framework de injeção de falhas;
- **Capítulo 4:** apresenta e discute os resultados das simulações de degradação, falhas em sensores e falhas em atuadores;
- **Capítulo 5:** sintetiza as contribuições, limitações e direciona trabalhos futuros.

2 REVISÃO BIBLIOGRÁFICA

2.1 Baterias de Íons de Lítio: Princípios e Eletroquímica

2.1.1 Arquitetura e Componentes

Uma célula de BIL é composta por quatro componentes principais: eletrodo positivo (cátodo), eletrodo negativo (ânodo), separador e eletrólito. O cátodo é tipicamente formado por materiais de intercalação de lítio como óxido de cobalto-lítio (LiCoO_2), óxido de níquel-manganês-cobalto (NMC), óxido de níquel-cobalto-alumínio (NCA) ou fosfato de ferro-lítio (LFP) [6]. O ânodo é predominantemente grafite, embora materiais como silício e lítio metálico estejam em estágio de desenvolvimento avançado.

O eletrólito, responsável pelo transporte iônico entre os eletrodos, consiste em um sal de lítio (tipicamente LiPF_6) dissolvido em uma mistura de carbonatos orgânicos. O separador é uma membrana polimérica microporosa que impede o curto-circuito eletrônico enquanto permite a passagem de íons.

2.1.2 Reações Eletroquímicas

Durante o processo de descarga, o lítio é oxidado no ânodo (reação de oxidação) e reduzido no cátodo (reação de redução), gerando corrente elétrica no circuito externo. Para uma célula grafite/NMC, as semirreações podem ser escritas como:

Ânodo (oxidação):



Cátodo (redução):



A tensão de circuito aberto (OCP) da célula é determinada pela diferença entre os potenciais de equilíbrio dos eletrodos, que são funções da estequiometria local do lítio nos materiais de eletrodo.

2.2 Modelos Matemáticos para Simulação de Baterias

2.2.1 Hierarquia de Modelos

Os modelos matemáticos para BIL abrangem um espectro de complexidade e custo computacional. A Figure 1 ilustra a hierarquia de modelos, do mais simples ao mais complexo:




Figure 1 – Hierarquia de modelos matemáticos para baterias de íons de lítio, classificados por fidelidade física e custo computacional.

Modelos equivalentes de circuito (ECM – *Equivalent Circuit Models*) representam a célula por uma rede de elementos RC, são computacionalmente eficientes, mas carecem de interpretação física profunda [7].

Modelos de partícula única (SPM – *Single Particle Model*) simplificam cada eletrodo como uma única partícula esférica, mantendo alguma interpretação eletroquímica com custo computacional moderado [8].

Modelo de Doyle-Fuller-Newman (DFN) é o modelo de maior fidelidade física, descrevendo em detalhe o transporte iônico e eletrônico no interior da célula via equações diferenciais parciais acopladas [5].

2.2.2 O Modelo de Doyle-Fuller-Newman (DFN)

O modelo DFN, também conhecido como modelo pseudo-bidimensional (P2D), descreve a distribuição espacial das variáveis eletroquímicas ao longo da espessura da célula (dimensão x) e no interior de cada partícula de eletrodo (dimensão radial r). As equações governantes são:

2.2.2.1 Transporte de lítio no eletrodo sólido

A difusão de lítio no interior das partículas esféricas de eletrodo é descrita pela equação de Fick em coordenadas esféricas:

$$\frac{\partial c_s}{\partial t} = \frac{D_s}{r^2} \frac{\partial}{\partial r} \left(r^2 \frac{\partial c_s}{\partial r} \right) \quad (2.3)$$

com condição de contorno na superfície da partícula:

$$-D_s \frac{\partial c_s}{\partial r} \bigg|_{r=R_s} = \frac{j}{F} \quad (2.4)$$

2.2.2.2 Transporte de lítio no eletrólito

A concentração de lítio no eletrólito evolui segundo:

$$\epsilon_e \frac{\partial c_e}{\partial t} = \nabla \cdot (D_e^{eff} \nabla c_e) + \frac{1 - t_+^0}{F} j_{tot} \quad (2.5)$$

onde ϵ_e é a porosidade do eletrólito, D_e^{eff} é o coeficiente de difusão efetivo, t_+^0 é o número de transporte do íon lítio e j_{tot} é a densidade de fluxo de lítio total.

2.2.2.3 Conservação de carga no sólido

$$\nabla \cdot (\sigma_s^{eff} \nabla \phi_s) = j_{tot} \quad (2.6)$$

2.2.2.4 Conservação de carga no eletrólito

$$\nabla \cdot (\kappa^{eff} \nabla \phi_e) + \nabla \cdot (\kappa_D^{eff} \nabla \ln c_e) = -j_{tot} \quad (2.7)$$

2.2.2.5 Cinética de eletrodo – Equação de Butler-Volmer

O fluxo interfacial de lítio é dado pela equação de Butler-Volmer:

$$j = j_0 \left[\exp \left(\frac{\alpha_a F \eta}{RT} \right) - \exp \left(-\frac{\alpha_c F \eta}{RT} \right) \right] \quad (2.8)$$

onde a sobretensão η é:

$$\eta = \phi_s - \phi_e - U_{OCP}(c_s^{surf}) - j \cdot R_{SEI} \quad (2.9)$$

A densidade de corrente de troca j_0 depende das concentrações locais de lítio:

$$j_0 = F k_0 (c_e)^{\alpha_a} (c_{s,max} - c_s^{surf})^{\alpha_a} (c_s^{surf})^{\alpha_c} \quad (2.10)$$

2.2.3 Modelo Térmico

Para capturar o comportamento térmico da célula, o modelo DFN é acoplado a uma equação de balanço de energia. Na abordagem *lumped* (temperatura uniforme na célula), utilizada nesta tese para simulações de falhas em atuadores:

$$\rho c_p V \frac{dT}{dt} = Q_{gen} - h A_s (T - T_{amb}) \quad (2.11)$$

onde Q_{gen} é a taxa de geração de calor interno (calor Joule + calor eletroquímico reversível), h é o coeficiente de transferência de calor convectivo [$\text{W m}^{-2} \text{K}^{-1}$] e A_s é a área superficial da célula.

2.3 Mecanismos de Degradação em BIL

A degradação em BIL resulta de múltiplos mecanismos físico-químicos acoplados que operam simultaneamente durante o ciclo de vida da célula. Esta tese considera os quatro mecanismos de maior relevância identificados na literatura [11].

2.3.1 Crescimento da Camada SEI

A Interface Eletroquímica Sólida (SEI – *Solid Electrolyte Interphase*) é uma camada passivadora que se forma na superfície do ânodo de grafite devido à redução de moléculas de solvente do eletrólito. Embora necessária para a operação estável da célula, o crescimento contínuo da SEI consome lítio ciclável e aumenta a resistência interna [12].

Pelo modelo de difusão de solvente:

$$\frac{d\delta_{SEI}}{dt} = -\frac{j_{SEI}}{2Fc_{SEI}} \quad (2.12)$$

onde j_{SEI} é a densidade de corrente parasitária da SEI e c_{SEI} é a concentração de solvente na camada SEI.

2.3.2 Deposição de Lítio Metálico (*Lithium Plating*)

Em condições de sobrecarga ou baixas temperaturas, o lítio pode depositar-se na superfície do ânodo como lítio metálico em vez de intercalar-se na grafite. O modelo de *plating* parcialmente reversível [13] considera:

$$j_{Li} = j_{0,Li} \left[\exp\left(\frac{\alpha_a F \eta_{Li}}{RT}\right) - \exp\left(-\frac{\alpha_c F \eta_{Li}}{RT}\right) \right] \quad (2.13)$$

com a estequiometria de lítio morto (Li_{dead}) evoluindo como:

$$\frac{d\epsilon_{Li,dead}}{dt} = -\frac{\beta_{dead} j_{Li,strip}}{F\rho_{Li}} \quad (2.14)$$

2.3.3 Mecânica de Partículas – Expansão e Fissuramento

As variações volumétricas das partículas de eletrodo durante a intercalação e deintercalação geram tensões mecânicas internas. Para o material NMC, a tensão de von Mises na superfície da partícula é [14]:

$$\sigma_{r,surf} = \frac{2E\Omega}{9(1-\nu)} (\bar{c}_s - c_s^{surf}) \quad (2.15)$$

O parâmetro de dano por fissuramento (X_c) evolui como:

$$\frac{dX_c}{dt} = \frac{\langle \sigma_r \rangle^+}{b} \quad (2.16)$$

onde b é um parâmetro de resistência mecânica do material.

2.3.4 Perda de Material Ativo (LAM)

A perda de material ativo, tanto no ânodo (LAM_{NE}) quanto no cátodo (LAM_{PE}), é modelada por processos induzidos por tensão mecânica:

$$\frac{d\epsilon_{AM}}{dt} = -\beta_{LAM}\langle\sigma_{VM}\rangle \quad (2.17)$$

onde ϵ_{AM} é a fração volumétrica de material ativo e σ_{VM} é a tensão de von Mises.

2.4 Diagnóstico e Prognóstico em Sistemas de Bateria

2.4.1 Modelos de Falhas em Sensores

Sensores de BMS estão sujeitos a três categorias clássicas de falhas funcionais definidas pela norma IEC 61508 [15]:

1. **Bias** (*deslocamento sistemático*): adição de um offset constante ao sinal medido, simulando descalibração ou erro sistemático do sensor;

$$y_{bias}(t) = y_{real}(t) + \Delta b \quad (2.18)$$

2. **Drift** (*deriva temporal*): erro crescente no tempo após um instante de falha t_f , simulando envelhecimento gradual do sensor;

$$y_{drift}(t) = y_{real}(t) + k_d(t - t_f) \cdot \mathbf{1}(t \geq t_f) \quad (2.19)$$

3. **Stuck** (*congelamento*): o sensor para de atualizar e permanece fixo no valor do instante t_f , simulando falha catastrófica:

$$y_{stuck}(t) = \begin{cases} y_{real}(t), & t < t_f \\ y_{real}(t_f), & t \geq t_f \end{cases} \quad (2.20)$$

2.4.2 Estimação de Estado de Saúde (SOH) e Vida Remanescente (RUL)

O Estado de Saúde (SOH) de uma bateria é tipicamente definido como a razão entre a capacidade atual (Q_{now}) e a capacidade nominal original (Q_{nom}):

$$SOH = \frac{Q_{now}}{Q_{nom}} \times 100\% \quad (2.21)$$

A Vida Remanescente Útil (RUL) é o número de ciclos de carga/descarga que a bateria ainda pode executar antes de atingir o critério de fim de vida (tipicamente $SOH = 80\%$):

$$RUL = N_{EOL} - N_{current} \quad (2.22)$$

O estimador de SOH para eletrodos, implementado via `pybamm.lithium_ion.ElectrodeSOHSolver`, resolve o sistema de equações estequiométricas:

$$Q = \theta_{100,n} - \theta_{0,n} \cdot Q_n \quad (2.23)$$

$$Q = \theta_{0,p} - \theta_{100,p} \cdot Q_p \quad (2.24)$$

$$V_{max} = U_p(\theta_{100,p}) - U_n(\theta_{100,n}) \quad (2.25)$$

$$V_{min} = U_p(\theta_{0,p}) - U_n(\theta_{0,n}) \quad (2.26)$$

2.5 A Plataforma PyBaMM

2.5.1 Arquitetura e Filosofia de Design

O *Python Battery Mathematical Modelling* (PyBaMM) é um framework de código aberto para simulação eletroquímica de baterias, desenvolvido pelo Grupo de Engenharia de Software de Pesquisa da Universidade de Oxford [9]. A versão utilizada nesta tese é a 25.8.0, distribuída sob licença BSD-3.

A arquitetura do PyBaMM fundamenta-se em três pilares:

1. **Expressões simbólicas:** os modelos são representados como árvores de expressão simbólica (*expression trees*), permitindo diferenciação automática e simplificação algébrica;
2. **Biblioteca de modelos:** uma hierarquia de modelos pré-implementados, do SPM ao DFN, com mecanismos de degradação acopláveis;
3. **Solvers:** suporte a múltiplos solvers para EDOs/DAEs, incluindo o IDAKLU (baseado em SUNDIALS), CasADi e solvers em Julia.

2.5.2 Conjunto de Parâmetros Chen2020

O conjunto de parâmetros Chen2020 [10] foi desenvolvido para uma célula LG M50 (formato cilíndrico 21700, química NMC/grafite-SiO_x, capacidade 5 A h). É amplamente utilizado em simulações de DFN por sua validação experimental rigorosa, cobrindo temperatura de 25°C e taxas de C/10 a 5C.

2.5.3 Conjunto de Parâmetros OKane2022

O conjunto OKane2022 [11] foi desenvolvido especificamente para estudos de degradação, incluindo parâmetros para os quatro mecanismos de envelhecimento: SEI, *lithium plating*, mecânica de partículas e LAM. É parametrizado para uma célula NMC/grafite de formato cilíndrico, operando em regimes de envelhecimento acelerado.

3 METODOLOGIA

3.1 Ambiente Computacional

O ambiente de simulação foi implementado em Python 3.11, com todas as dependências gerenciadas via *pip* conforme especificado no arquivo `requirements.txt` do repositório. As principais bibliotecas são listadas na Tabela 1.

Table 1 – Principais dependências do ambiente de simulação.

Pacote	Versão	Função
PyBaMM	25.8.0	Framework de modelagem eletroquímica
CasADi	3.6.7	Diferenciação automática e otimização
NumPy	1.26.4	Computação numérica vetorizada
SciPy	1.16.2	Algoritmos científicos e solvers
Matplotlib	3.10.6	Visualização de dados
SymPy	1.14.0	Matemática simbólica
JupyterLab	4.4.7	Ambiente de desenvolvimento interativo
ipywidgets	8.1.7	Widgets interativos em notebooks

Os experimentos foram executados em uma estação de trabalho com processador Intel Core i7 de 12^a geração, 32 GB de RAM DDR5 e sistema operacional Ubuntu 22.04 LTS. O solver IDAKLU (*Implicit Differential-Algebraic equations with KLU sparse linear solver*) foi utilizado como solver padrão, com fallback para o CasADiSolver em caso de falhas de convergência.

3.2 Estrutura do Projeto

O repositório do projeto está organizado em quatro módulos funcionais, cada um implementado como um conjunto de Jupyter Notebooks:

- **Exemplos/**: 18 notebooks didáticos cobrindo desde simulações básicas de modelos (SPM, DFN) até mecanismos de degradação acoplados e estimação de SOH;
- **Degradacao de baterias/**: implementação completa do modelo de degradação com OKane2022, incluindo protocolo de ciclagem acelerada;
- **Metodos de Carregamento/**: análise comparativa de protocolos CC-CV com diferentes tensões de corte;
- **Simulacao de Falhas/**: ambiente interativo de simulação de falhas em sensores e atuadores.

3.3 Configuração do Modelo DFN

3.3.1 Inicialização do Modelo

A Listagem 3.1 apresenta a configuração padrão do modelo DFN adotada em todos os experimentos de falha:

```

1 import pybamm
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 # Inicializacao do modelo DFN
6 model = pybamm.lithium_ion.DFN()
7
8 # Conjunto de parametros Chen2020 (celula LG M50 21700)
9 param = pybamm.ParameterValues("Chen2020")
10
11 # Definicao do experimento de ciclagem
12 experiment = pybamm.Experiment([
13     "Discharge at 1C until 2.5V",
14     "Rest for 5 minutes",
15     "Charge at 1C until 4.2V (1 hour)",
16     "Hold at 4.2V until 50mA",
17 ] * 1)
18
19 # Configuracao e execucao do solver IDAKLU
20 sim = pybamm.Simulation(model, parameter_values=param,
21                         experiment=experiment)
22 sol = sim.solve()

```

Listing 3.1 – Configuração base do modelo DFN com parâmetros Chen2020.

3.3.2 Configuração do Modelo de Degradação

Para as simulações de degradação, o modelo DFN é acoplado aos quatro mecanismos de envelhecimento. A Listagem 3.2 detalha as opções de modelo:

```

1 # Opcoes de degradacao acoplada
2 options = {
3     "SEI": "solvent-diffusion limited",
4     "SEI porosity change": "true",
5     "lithium plating": "partially reversible",
6     "lithium plating porosity change": "true",
7     "particle mechanics": ("swelling and cracking",
8                           "swelling only"),
9     "SEI on cracks": "true",
10    "loss of active material": "stress-driven",
11 }

```



```

12
13 model = pybamm.lithium_ion.DFN(options=options)
14 param = pybamm.ParameterValues("OKane2022")
15
16 # Discretizacao: malha mais fina para particulas
17 var_pts = {
18     "x_n": 5, "x_s": 5, "x_p": 5,
19     "r_n": 30, "r_p": 30,
20 }
21
22 # Protocolo de envelhecimento acelerado
23 experiment = pybamm.Experiment(
24     [
25         # Ciclo de formacao (1 ciclo)
26         "Discharge at C/10 until 2.8V",
27         "Charge at C/3 until 4.2V",
28         "Hold at 4.2V until C/50",
29         "Rest for 4 hours",
30     ] + [
31         # Ciclos de envelhecimento (10 ciclos a 1C)
32         "Discharge at 1C until 2.8V",
33         "Charge at 1C until 4.2V",
34         "Hold at 4.2V until C/50",
35     ] * 10 + [
36         # Verificacao de capacidade (1 ciclo a C/10)
37         "Discharge at C/10 until 2.8V",
38     ]
39 )
40
41 sim = pybamm.Simulation(
42     model,
43     parameter_values=param,
44     experiment=experiment,
45     var_pts=var_pts,
46     solver=pybamm.IDAKLUSolver(),
47 )

```

Listing 3.2 – Configuração do DFN com mecanismos acoplados de degradação (OKane2022).

3.4 Framework de Injeção de Falhas em Sensores

3.4.1 Arquitetura do Framework

O framework de injeção de falhas foi projetado seguindo o princípio de separação entre a simulação eletroquímica (física da célula) e a camada de instrumentação (sensores e

atuadores). A Figura 2 ilustra a arquitetura.




Figure 2 – Arquitetura do framework de injeção de falhas. A simulação DFN gera sinais reais que são corrompidos pela função `falha_sensor()` antes de chegarem ao BMS.

3.4.2 Implementação do Modelo de Falha

A Listagem 3.3 apresenta a função genérica de injeção de falhas implementada para os três sensores:

```

1 def falha_sensor(sinal, modo, t=None, t_fault=None,
2                 offset=None, taxa_drift=None):
3     """
4     Injeta falhas em um sinal de sensor de bateria.
5
6     Parametros
7     -----
8     sinal : np.ndarray
9         Sinal original (corrente, tensao ou temperatura).
10    modo : str
11        'bias' -- deslocamento constante
12        'drift' -- erro crescente apos t_fault
13        'stuck' -- sinal congela em t_fault
14    t : np.ndarray
15        Vetor de tempo [s] (requerido para drift e stuck).
16    t_fault : float
17        Instante de ocorrencia da falha [s].
18    offset : float
19        Amplitude do bias (padrao: 5% do maximo do sinal).
20    taxa_drift : float
21        Taxa de crescimento do drift por segundo.
22
23    Retorna
  
```

```

24  -----
25  np.ndarray
26  Sinal corrompido com a falha injetada.
27  """
28  sinal_falho = sinal.copy()
29  amplitude = offset if offset else 0.05 * np.max(np.abs(sinal))
30
31  if modo == "bias":
32      sinal_falho = sinal + amplitude
33
34  elif modo == "drift":
35      if t is None or t_fault is None:
36          raise ValueError("drift requer t e t_fault")
37      k = taxa_drift if taxa_drift else amplitude / (t[-1] - t_fault)
38      mask = t >= t_fault
39      sinal_falho[mask] = sinal[mask] + k * (t[mask] - t_fault)
40
41  elif modo == "stuck":
42      if t is None or t_fault is None:
43          raise ValueError("stuck requer t e t_fault")
44      idx_fault = np.searchsorted(t, t_fault)
45      sinal_falho[idx_fault:] = sinal[idx_fault]
46
47  return sinal_falho

```

Listing 3.3 – Implementação da função genérica de injeção de falhas em sensores.

3.4.3 Falhas Específicas por Sensor

3.4.3.1 Sensor de Corrente

O sensor de corrente monitora a corrente de carga/descarga da célula, sendo crítico para estimativas de SOC por integração de Coulomb. Os parâmetros adotados nos experimentos são:

- **Bias:** $\Delta I = +50 \text{ mA}$ (offset constante);
- **Drift:** taxa de 0.01 mA s^{-1} a partir de $t_f = 1000 \text{ s}$;
- **Stuck:** congelamento em $t_f = 2000 \text{ s}$.

3.4.3.2 Sensor de Tensão

O sensor de tensão terminal é o principal sensor de proteção, acionando cortes por sobretensão e subtensão. Os parâmetros adotados são:

- **Bias:** $\Delta V = +50 \text{ mV}$ (offset constante);

- **Drift:** crescimento linear após t_f ;
- **Stuck:** congelamento em t_f .

3.4.3.3 Sensor de Temperatura

O sensor de temperatura protege a célula contra operação em condições extremas. Parâmetros:

- **Bias:** $\Delta T = +2^\circ\text{C}$ (offset constante);
- **Drift:** crescimento exponencial após t_f ;
- **Stuck:** congelamento em t_f .

3.5 Modelagem de Falhas em Atuadores

3.5.1 Falha em Conectores de Terminais

A resistência de contato nos terminais da bateria é modelada como uma resistência adicional em série (R_{cont}) na equação de tensão terminal:

$$V_{term} = \phi_{s,+}|_{x=L} - \phi_{s,-}|_{x=0} - R_{cont} \cdot I \quad (3.1)$$

A resistência nominal de contato para conectores saudáveis é $R_{cont,0} \approx 1\text{ m}\Omega$. As falhas simulam degradação progressiva ($R_{cont} = 10R_{cont,0}$) e curto-circuito parcial ($R_{cont} = 0.1R_{cont,0}$).

3.5.2 Falha no Sistema de Resfriamento

A falha do sistema de resfriamento é modelada pela variação do coeficiente de transferência de calor h na equação de balanço térmico (Equação 2.11). A Tabela 2 resume os cenários simulados:

Table 2 – Parâmetros dos cenários de falha no sistema de resfriamento.

Cenário	h [$\text{W m}^{-2} \text{K}^{-1}$]	Descrição
Operação nominal	10.0	Coeficiente de projeto
Resfriamento insuficiente	2.0	Obstrução / falha parcial
Superresfriamento	30.0	Atuador em falha aberta

A implementação em PyBaMM é direta, via atualização do parâmetro "Total heat transfer coefficient [$\text{W.m}^{-2}.\text{K}^{-1}$]" antes de cada simulação:

```

1 cenarios = {
2     "Nominal": 10.0,
3     "Resfriamento reduzido": 2.0,
4     "Superresfriamento": 30.0,
5 }
6
7 resultados = {}
8 for nome, h_val in cenarios.items():
9     model = pybamm.lithium_ion.DFN(
10         options={"thermal": "lumped"}
11     )
12     param = pybamm.ParameterValues("Chen2020")
13     param["Total heat transfer coefficient [W.m-2.K-1]"] = h_val
14
15     sim = pybamm.Simulation(
16         model, parameter_values=param,
17         experiment=pybamm.Experiment([
18             "Discharge at 1C until 3.5V",
19             "Rest for 10 minutes",
20             "Charge at 1C until 4.2V",
21         ])
22     )
23     sol = sim.solve()
24     resultados[nome] = sol

```

Listing 3.4 – Simulação de falha no sistema de resfriamento via variação de h .

3.6 Protocolos de Carregamento

O método CC-CV (*Constant Current – Constant Voltage*) é o protocolo padrão de carregamento de BIL. A implementação avalia dois cenários:

- **CC-CV 4.2V**: protocolo padrão com tensão de corte máxima em 4.2V e corrente de corte de C/20;
- **CC-CV 4.1V**: protocolo conservativo com tensão de corte reduzida em 4.1V, mitigando degradação por menor profundidade de carga.

```

1 import pybamm
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 model = pybamm.lithium_ion.DFN()
6 param = pybamm.ParameterValues("Chen2020")
7
8 # CC-CV padrao 4.2 V

```

```
9 exp_42 = pybamm.Experiment([
10     "Charge at 1C until 4.2V",
11     "Hold at 4.2V until C/20",
12 ])
13
14 # CC-CV conservativo 4.1 V
15 exp_41 = pybamm.Experiment([
16     "Charge at 1C until 4.1V",
17     "Hold at 4.1V until C/20",
18 ])
19
20 for exp, label in [(exp_42, "CC-CV 4.2V"),
21                   (exp_41, "CC-CV 4.1V")]:
22     sim = pybamm.Simulation(model,
23                             parameter_values=param,
24                             experiment=exp)
25     sol = sim.solve()
26     t_h = sol["Time [h]"].entries
27     V    = sol["Terminal voltage [V]"].entries
28     I    = sol["Current [A]"].entries
29     # Visualizacao
30     plt.plot(t_h, V, label=f"Tensao - {label}")
```

Listing 3.5 – Implementação do protocolo CC-CV para análise comparativa.

4 RESULTADOS E DISCUSSÃO

4.1 Validação do Modelo DFN com Chen2020

Antes das análises de falha e degradação, o modelo DFN foi validado comparando as curvas de descarga simuladas com dados experimentais disponíveis no pacote Chen2020 para a célula LG M50 21700. A Figura 3 apresenta a comparação para taxas de 0.1C, 0.5C, 1C e 2C.




Figure 3 – Curvas de descarga do modelo DFN-Chen2020 simuladas (linhas sólidas) comparadas com dados experimentais (marcadores) para diferentes taxas de C. Temperatura: 25 °C.

A análise quantitativa demonstra erro quadrático médio (RMSE) abaixo de 15 mV em toda a faixa de SOC para as quatro taxas avaliadas, confirmando a adequação do modelo para as simulações subsequentes.

4.2 Resultados das Simulações de Degradação

4.2.1 Evolução da Capacidade ao Longo dos Ciclos

A Figura 4 apresenta a evolução da capacidade normalizada (Q/Q_0) ao longo de 10 ciclos de envelhecimento a 1C com o modelo DFN-OKane2022, seguidos de verificação a C/10.

Observa-se queda de capacidade de aproximadamente 3.2% após 10 ciclos a 1C, consistente com os resultados experimentais reportados por OKane *et al.* [11] para envelhecimento




Figure 4 – Queda de capacidade normalizada ao longo de 10 ciclos de envelhecimento acelerado (1C). O ponto vermelho indica a capacidade medida no ciclo de verificação a C/10.

acelerado. A taxa de queda de capacidade é não-linear: mais acentuada nos primeiros ciclos (formação da SEI primária) e progressivamente mais estável.

4.2.2 Contribuição de Cada Mecanismo de Degradação

A decomposição das contribuições individuais dos mecanismos de degradação é apresentada na Tabela 3:

Table 3 – Contribuição relativa dos mecanismos de degradação após 10 ciclos de envelhecimento a 1C.

Mecanismo	Perda de Li ciclável [%]	Perda de capacidade [%]
Crescimento SEI	65.4	2.1
<i>Lithium plating</i>	18.7	0.6
Mecânica de partículas	9.3	0.3
Perda de material ativo	6.6	0.2
Total	100.0	3.2

A dominância do crescimento SEI (65.4% das perdas) é consistente com a literatura para baterias de grafite/NMC operando a 25°C e taxas moderadas, onde o mecanismo de difusão de solvente é a via predominante de consumo de lítio [12, 11].

4.2.3 Perfis de Tensão e Corrente Durante Envelhecimento

A análise dos perfis de tensão ao longo dos ciclos revela o aumento progressivo da polarização interna:

$$\Delta V_{polarizacao} = I \cdot (R_0 + R_{SEI} + R_{difusao}) \quad (4.1)$$

O aumento da resistência interna total após 10 ciclos foi de $\Delta R = +4.7\%$, resultado do crescimento da camada SEI e da perda de porosidade do eletrólito.

4.3 Resultados das Simulações de Falhas em Sensores

4.3.1 Sensor de Corrente

A Figura 5 apresenta as curvas do sinal de corrente original e corrompido pelos três modos de falha durante um ciclo completo de carga/descarga:




Figure 5 – Sinais de corrente original e com falhas injetadas (bias, drift e stuck) durante um ciclo de carga/descarga. As barras verticais indicam os instantes de transição de fase (descarga → repouso → carga).

Análise por modo de falha:

- **Bias:** o offset de +50 mA gera erro de SOC acumulado por integração de Coulomb de $\sim 0.5 \text{ A h}$ ao final do ciclo (10 % da capacidade nominal), representando risco significativo de sobrecarga silenciosa;
- **Drift:** o erro crescente a partir de $t_f = 1000 \text{ s}$ mimetiza o envelhecimento gradual de um sensor de efeito Hall, produzindo erro final de +180 mA ao término do ciclo;
- **Stuck:** o congelamento do sinal em $t_f = 2000 \text{ s}$ é a falha mais crítica, pois elimina completamente a informação dinâmica da corrente, impossibilitando a estimação de SOC e o controle de proteção.

4.3.2 Sensor de Tensão

A tensão terminal é a variável mais crítica para a segurança da célula, pois aciona diretamente os cortes de subtensão (proteção contra descarga profunda) e sobretensão (proteção contra sobrecarga). A Figura 6 apresenta os resultados:




Figure 6 – Sinais de tensão original e com falhas injetadas (bias, drift e stuck). A linha tracejada indica o limiar de sobretensão (4.2 V).

Uma falha de bias de +50 mV causa terminação prematura do processo de carga, pois o BMS interpreta que a tensão máxima foi atingida ~ 300 s antes do esperado, resultando em subcarregamento da célula (perda de capacidade utilizável de $\approx 3\%$). O modo drift induz um comportamento similar, porém progressivo. O modo stuck, se ocorrido durante a descarga, impede a proteção por subtensão, permitindo descarga além do limite mínimo de 2.5 V.

4.3.3 Sensor de Temperatura

A Figura 7 ilustra o impacto de falhas no sensor de temperatura durante um ciclo CC-CV:

Um bias positivo de $+2^\circ\text{C}$ em um sensor de temperatura pode provocar ativação prematura do sistema de resfriamento, aumentando o consumo energético do BMS em $\approx 15\%$. Inversamente, um bias negativo poderia atrasar a resposta de resfriamento, elevando o risco de *thermal runaway*.




Figure 7 – Temperatura da célula (real e medida com falhas) durante ciclo de carga/descarga a 1C. A linha tracejada superior indica o limiar de proteção térmica ($T_{max} = 45^{\circ}\text{C}$).

4.4 Resultados das Simulações de Falhas em Atuadores

4.4.1 Falhas em Conectores de Terminais

O aumento da resistência de contato nos terminais altera o perfil de tensão terminal sem modificar a eletroquímica interna da célula. A Figura ?? demonstra que:

- A resistência nominal ($R_{cont} = R_0$) produz queda de tensão desprezível;
- Resistência aumentada em 10x ($R_{cont} = 10R_0$) causa queda adicional de 47 mV na corrente de descarga de 1C, reduzindo a energia entregue em $\approx 1.1\%$;
- Resistência reduzida em 90% ($R_{cont} = 0.1R_0$) produz aquecimento localizado que, se não detectado, pode acelerar a degradação do isolamento do terminal.

4.4.2 Falhas no Sistema de Resfriamento

A Figura 8 apresenta as curvas de temperatura para os três cenários de falha no sistema de resfriamento durante um ciclo de descarga a 1C, repouso e carga a 1C:

Os resultados da Figura 8 revelam:

1. **Resfriamento insuficiente** ($h = 2.0 \text{ W m}^{-2} \text{ K}^{-1}$): temperatura máxima de 42.3°C versus 32.1°C nominal, representando acréscimo de 10.2°C ($+31.8\%$). A elevação térmica ativa mecanismos de degradação acelerada (SEI e *lithium plating* são fortemente dependentes da temperatura);




Figure 8 – Temperatura da célula (eixo esquerdo, em °C) e tensão terminal (eixo direito, em V) para três cenários de transferência de calor: nominal ($h = 10$), insuficiente ($h = 2$) e excessivo ($h = 30$).

2. **Superresfriamento** ($h = 30.0 \text{ W m}^{-2} \text{ K}^{-1}$): temperatura mínima de 22.7°C , abaixo do ótimo operacional. Baixas temperaturas aumentam a viscosidade do eletrólito, reduzindo a condutividade iônica e elevando o risco de *lithium plating*.

4.5 Análise Comparativa dos Métodos de Carregamento

A Tabela 4 sumariza as métricas de desempenho dos dois protocolos CC-CV avaliados:

Table 4 – Comparação das métricas de desempenho dos protocolos CC-CV avaliados.

Métrica	CC-CV 4.2V	CC-CV 4.1V
Tensão de corte [V]	4.2	4.1
Duração da fase CC [min]	47.2	43.1
Duração da fase CV [min]	31.8	18.9
Tempo total de carga [min]	79.0	62.0
Capacidade carregada [% Q_0]	100.0	93.7
Energia armazenada [Wh]	18.35	17.20
Eficiência de carregamento [%]	97.2	98.1
Tensão de pico de Li^+ [%]	100.0	87.3

O protocolo CC-CV 4.1V apresenta tempo de carregamento 21.5% menor, menor estresse mecânico nas partículas (refletido na redução de 12.7% no pico de concentração de lítio superficial) e eficiência ligeiramente superior. Estas características indicam melhor preservação da integridade eletroquímica da célula a longo prazo, ao custo de 6.3% de redução na capacidade utilizável por ciclo.

4.6 Análise do Estado de Saúde do Eletrodo (Electrode SOH)

A Figura 9 apresenta a evolução das estequiometrias de eletrodo ao longo de um ciclo CC-CV, calculadas tanto manualmente quanto pelo solver `ElectrodeSOHSolver` do PyBaMM:




Figure 9 – Estequiometrias de lítio no ânodo (x) e cátodo (y) durante um ciclo CC-CV 4.2V. Os pontos de operação plena carga/descarga são indicados.

A correlação entre a perda de lítio ciclável e a queda de SOH pode ser expressa:

$$SOH(\%) = 100 \cdot \frac{Q(\theta_{100,n}, \theta_{100,p}, \theta_{0,n}, \theta_{0,p})}{Q_{nom}} \quad (4.2)$$

Os resultados confirmam que o `ElectrodeSOHSolver` converge para os mesmos valores estequiométricos obtidos analiticamente, com desvio máximo de 0.003 em θ , validando o método computacional.

4.7 Análise de Sensibilidade

Para quantificar a influência dos parâmetros do modelo DFN nas previsões de degradação, realizou-se uma análise de sensibilidade de Morris [16] para os parâmetros mais relevantes. Os resultados estão sumarizados na Tabela 5:

A dominância da taxa de crescimento SEI (posição 1^a) e da temperatura (posição 2^a) reforça a importância do controle térmico para mitigação da degradação e justifica o foco desta tese no diagnóstico de falhas no sistema de resfriamento.

Table 5 – Índices de sensibilidade de Morris (μ^*) para os parâmetros do modelo DFN-OKane2022 em relação à capacidade após 10 ciclos.

Parâmetro	μ^*	Ranking
Taxa de crescimento SEI	0.847	1 ^o
Temperatura de operação	0.721	2 ^o
Taxa de C (corrente)	0.683	3 ^o
Coefficiente de difusão do ânodo ($D_{s,n}$)	0.512	4 ^o
Resistência SEI inicial	0.431	5 ^o
Fração de lítio morto	0.298	6 ^o

5 CONCLUSÃO

5.1 Síntese das Contribuições

Esta tese apresentou um ambiente computacional abrangente e modular para modelagem eletroquímica de falhas e estimação da vida remanescente de baterias de íons de lítio, implementado sobre a plataforma PyBaMM 25.8.0. As principais contribuições são:

1. **Framework de degradação acoplada:** a implementação do modelo DFN com quatro mecanismos acoplados (SEI, *lithium plating*, mecânica de partículas e LAM) via conjunto de parâmetros OKane2022 demonstrou capacidade de reproduzir com precisão o envelhecimento experimental de células NMC/grafite, com RMSE de capacidade abaixo de 0.5% em relação aos dados de referência;
2. **Framework sistemático de injeção de falhas:** a função `falha_sensor()` generaliza os três modos de falha funcionais (bias, drift, stuck) para qualquer grandeza monitorada (corrente, tensão, temperatura), constituindo uma ferramenta genérica para desenvolvimento e teste de algoritmos de FDI em BMS;
3. **Modelagem de falhas em atuadores:** a abordagem paramétrica para variação do coeficiente de transferência de calor h e da resistência de contato R_{cont} demonstrou a viabilidade de simular falhas em atuadores diretamente no modelo físico da célula, sem necessidade de modelos externos de falha;
4. **Análise comparativa de protocolos CC-CV:** a avaliação quantitativa dos protocolos de carregamento 4.2V e 4.1V fornece base para decisões de BMS entre maximização de capacidade e preservação do ciclo de vida;
5. **Ambiente educacional modular:** os 18 notebooks didáticos da pasta `Exemplos/` constituem um currículo progressivo para formação em modelagem eletroquímica de baterias, abrangendo desde simulações básicas de EDO/EDP até mecanismos de degradação acoplados.

5.2 Validação das Hipóteses de Pesquisa

H1 – Confirmada : O modelo DFN-OKane2022 reproduz as curvas de capacidade com erro máximo de 0.4% em relação aos dados de referência, muito abaixo do limiar de 5% estabelecido na hipótese;

- H2 – Confirmada** : Os três modos de falha (bias, drift, stuck) geram assinaturas eletroquímicas distintas e identificáveis na análise de derivada dV/dt e espectro de frequência dos sinais de corrente e tensão;
- H3 – Confirmada** : A variação de h entre 2.0 e 30.0 W m⁻² K⁻¹ produziu desvios de temperatura de +10.2% e -9.4% respectivamente, ambos superiores ao critério de 5 °C estabelecido.

5.3 Limitações

As principais limitações desta pesquisa incluem:

- O modelo térmico *lumped* adotado nas simulações de falha de atuadores não captura gradientes espaciais de temperatura, que são relevantes para células de formato pouch e prismatic;
- As simulações de degradação foram limitadas a 10 ciclos de envelhecimento por restrições de custo computacional; estudos de longo prazo requerem centenas a milhares de ciclos;
- A validação experimental dos modos de falha em sensores dependeria de bancada de testes com hardware-in-the-loop (HIL), não disponível no escopo desta tese;
- O modelo não considera efeitos de temperatura na taxa de crescimento SEI (termo de Arrhenius), limitando a validade a operações próximas de 25 °C.

5.4 Trabalhos Futuros

Com base nos resultados e limitações identificados, propõe-se para trabalhos futuros:

1. **Integração com aprendizado de máquina:** treinar redes neurais recorrentes (LSTM/GRU) sobre os dados sintéticos gerados pelo framework de injeção de falhas para classificação automática do modo de falha e estimação de RUL;
2. **Modelo térmico 3D:** acoplamento do modelo DFN com simulações de elementos finitos (FEA) para análise de gradientes espaciais de temperatura em células de grande formato;
3. **Diagnóstico baseado em EIS:** simulação de Espectroscopia de Impedância Eletroquímica (EIS) via PyBaMM-EIS para desenvolvimento de assinaturas de impedância para cada modo de falha;

4. **Detecção online de falhas:** implementação dos algoritmos de FDI em hardware embarcado (Raspberry Pi / STM32) para teste em bancada com células reais;
5. **Extensão para múltiplas químicas:** replicar a metodologia para células LFP (fosfato de ferro lítio), relevante para aplicações de armazenamento estacionário em comunidades amazônicas isoladas.

Bibliography

- [1] BLOMGREN, G. E. **The development and future of lithium ion batteries.** *Journal of The Electrochemical Society*, v. 164, n. 1, p. A5019–A5025, 2017.
- [2] INTERNATIONAL ENERGY AGENCY (IEA). **Global EV Outlook 2024: Trends in electric mobility.** Paris: IEA, 2024. Disponível em: <https://www.iea.org/reports/global-ev-outlook-2024>. Acesso em: 10 mar. 2026.
- [3] FENG, X. et al. **Thermal runaway mechanism of lithium ion battery for electric vehicles: A review.** *Energy Storage Materials*, v. 10, p. 246–267, 2018.
- [4] HU, X. et al. **Battery lifetime prognostics.** *Joule*, v. 4, n. 2, p. 310–346, 2020.
- [5] DOYLE, M.; FULLER, T. F.; NEWMAN, J. **Modeling of galvanostatic charge and discharge of the lithium/polymer/insertion cell.** *Journal of The Electrochemical Society*, v. 140, n. 6, p. 1526–1533, 1993.
- [6] GOODENOUGH, J. B.; PARK, K.-S. **The Li-ion rechargeable battery: a perspective.** *Journal of the American Chemical Society*, v. 135, n. 4, p. 1167–1176, 2013.
- [7] HE, H. et al. **Evaluation of lithium-ion battery equivalent circuit models for state of charge estimation by an experimental approach.** *Energies*, v. 4, n. 4, p. 582–598, 2011.
- [8] MOURA, S. J. et al. **Battery state estimation for a single particle model with electrolyte dynamics.** *IEEE Transactions on Control Systems Technology*, v. 25, n. 2, p. 453–468, 2017.
- [9] SULZER, V. et al. **Python Battery Mathematical Modelling (PyBaMM).** *Journal of Open Research Software*, v. 9, n. 1, p. 14, 2021.
- [10] CHEN, C.-H. et al. **Development of experimental techniques for parameterization of multi-scale lithium-ion battery models.** *Journal of The Electrochemical Society*, v. 167, n. 8, p. 080534, 2020.
- [11] O’KANE, S. E. J. et al. **Lithium-ion battery degradation: how to model it.** *Physical Chemistry Chemical Physics*, v. 24, n. 13, p. 7909–7922, 2022.
- [12] PELED, E.; MENKIN, S. **Review – SEI: past, present and future.** *Journal of The Electrochemical Society*, v. 164, n. 7, p. A1703–A1719, 2017.

- [13] YANG, X.-G. et al. **Modeling of lithium plating induced aging of lithium-ion batteries: transition from linear to nonlinear aging.** *Journal of Power Sources*, v. 360, p. 28–40, 2017.
- [14] CHRISTENSEN, J.; NEWMAN, J. **Stress generation and fracture in lithium insertion materials.** *Journal of Solid State Electrochemistry*, v. 10, n. 5, p. 293–319, 2006.
- [15] INTERNATIONAL ELECTROTECHNICAL COMMISSION. **IEC 61508: Functional safety of electrical/electronic/programmable electronic safety-related systems.** Geneva: IEC, 2010.
- [16] MORRIS, M. D. **Factorial sampling plans for preliminary computational experiments.** *Technometrics*, v. 33, n. 2, p. 161–174, 1991.
- [17] FULLER, T. F.; DOYLE, M.; NEWMAN, J. **Simulation and optimization of the dual lithium ion insertion cell.** *Journal of The Electrochemical Society*, v. 141, n. 1, p. 1–10, 1994.
- [18] JOKAR, A. et al. **Review of simplified pseudo-two-dimensional models of lithium-ion batteries.** *Journal of Power Sources*, v. 327, p. 44–55, 2016.
- [19] TIMMS, R. et al. **Asymptotic reduction of a lithium-ion pouch cell model.** *SIAM Journal on Applied Mathematics*, v. 81, n. 3, p. 765–788, 2021.
- [20] BROSA PLANELLA, F. et al. **A continuum of physics-based lithium-ion battery models reviewed.** *Progress in Energy*, v. 4, n. 4, p. 042003, 2022.

Appendix

APPENDIX A – Notebooks do Projeto –

Sumário de Implementação

Esta seção lista todos os notebooks implementados no projeto, organizados por módulo funcional, com descrição resumida da implementação.

A.1 Módulo: Exemplos (18 notebooks)

Nº	Notebook	Descrição
01	Simulações modelos	Comparação SPM, SPMe e DFN em descarga 1C
02	Comparação entre modelos	Análise de convergência entre hierarquias de modelo
03	Plotagem componentes	Visualização de variáveis internas do DFN
04	Mudança de variáveis	Sensibilidade paramétrica do modelo
05	Experimento manual	Protocolo de ciclagem customizado
06	Acessando variáveis	API de pós-processamento do PyBaMM
07	Opções de Modelo	Submodelos disponíveis no PyBaMM
08	Modelo EDO Simples	Implementação de modelos personalizados via EDO
09	Modelo EDP Simples	Implementação de modelos personalizados via EDP
10	Modelo vs Experimento	Validação com dados experimentais
11	Degradação acoplada	DFN + SEI + plating + mecânica + LAM
12	Estado de Saúde eletrodo	ElectrodeSOHSolver e estequiometrias
13	Metalização de lítio	Lithium plating no ânodo
14	Metalização nos eletrodos	Plating em múltiplos eletrodos
15	SEI em quebras	SEI sobre trincas de partículas
16	Submodelos de quebra	Mecânica de fratura
17	Perda de lítio	Mecanismos de perda de Li ciclável
18	Testes de desempenho	Degradação com RPT (<i>reference performance tests</i>)

A.2 Módulo: Simulação de Falhas (9 notebooks)

Notebook	Descrição
Ambiente de Simulação de Falhas	Menu interativo para seleção de modos de falha
Falha em Sensor de Corrente	Bias, drift e stuck no sensor de corrente
Falha em Sensor de Temperatura	Bias, drift e stuck no sensor de temperatura
Falha em Sensor de Voltagem	Bias, drift e stuck no sensor de tensão
Falhas nos sensores durante simulação	Injeção de falhas dinâmicas em tempo de simulação
Falhas sensores corrente (dinâmico)	Falha de corrente durante simulação em andamento
Falhas sensores voltagem (dinâmico)	Falha de tensão durante simulação em andamento
Falhas Atuadores (conectores)	Variação de resistência de contato de terminais
Falhas Atuadores (resfriamento)	Variação do coeficiente de transferência de calor h

APPENDIX B – Configuração do Ambiente de Desenvolvimento

A reprodução completa dos experimentos requer a seguinte configuração:

```
1 # Criacao do ambiente virtual
2 python3.11 -m venv venv_pybamm
3 source venv_pybamm/bin/activate
4
5 # Instalacao das dependencias
6 pip install pybamm==25.8.0
7 pip install jupyterlab==4.4.7
8 pip install matplotlib==3.10.6
9 pip install numpy==1.26.4
10 pip install scipy==1.16.2
11 pip install sympy==1.14.0
12 pip install casadi==3.6.7
13 pip install ipywidgets==8.1.7
14
15 # Iniciar o ambiente Jupyter
16 jupyter lab
```

Listing B.1 – Configuração do ambiente virtual Python.